

EY Data Challenge

Marzo 2025

Integrantes

- Jonathan Gutierrez
- Angélica B. Pérez Morales

1 Introducción

En línea con los Objetivos de Desarrollo Sostenible de las Naciones Unidas y el programa EY Ripples.

El desafío de IA y datos de 2025 se centra en un fenómeno conocido como el efecto de isla de calor urbano, una situación que ocurre debido a la alta densidad de edificios y la falta de espacios verdes y cuerpos de agua en las áreas urbanas. Las variaciones de temperatura entre entornos rurales y urbanos pueden superar los 10 grados Celsius en algunos casos y causar importantes problemas de salud, sociales y energéticos. Entre las personas particularmente vulnerables a los problemas relacionados con el calor se encuentran los niños pequeños, los adultos mayores, los trabajadores al aire libre y las poblaciones de bajos ingresos. Todos los resultados del desafío pueden ayudar a brindar alivio en materia de refrigeración a las comunidades vulnerables.

2 Objetivo

Desarrollar un modelo de aprendizaje automático para predecir los puntos críticos de islas de calor en una ubicación urbana.

OBJETIVO ESPECIFICO: El modelo debe estar diseñado para discernir y destacar los factores clave que contribuyen significativamente al desarrollo de estos puntos críticos dentro de los entornos urbanos.

3 Contexto de los Datos

El 24 de julio de 2021 se recopilieron datos de temperatura del aire cerca de la superficie en formato de índice en las regiones del Bronx y Manhattan de la ciudad de Nueva York en los Estados Unidos. Los datos se recopilaban por la tarde, entre las 15:00 y las 16:00 horas. Este conjunto de datos incluye marcas de tiempo, puntos de recorrido (latitud y longitud) y los valores correspondientes del índice de isla de calor urbana (UHI) para 11229 puntos de datos. Estos valores del índice UHI son los parámetros de destino para su modelo.

4 Datos adicionales: Indices

En el presente trabajo se hizo uso de los datos provenientes del satélite Sentinel 2, para elaborar los índices de NDVI, NDWI y NDBI.

5 Metodología

El proceso que engloba la metodología de esta solución se puede apreciar en la figura 1 que se presenta a continuación, en donde de manera simplificada se muestra la adquisición del dataset a utilizar, su análisis y el proceso de enriquecer este dataset con el fin de poder mejorar los resultados de predicción, la división de datos y los elementos requeridos para realizar el entrenamiento y prueba de nuestra solución.

crear y agregar figura 1 (en proceso)

Debido a que el dataset original presenta limitaciones en el periodo de tiempo de sus datos, específicamente tener una ventana de tiempo de una hora para el análisis nos pareció limitante para englobar más variables en el análisis, además de que dentro de esa ventana de tiempo el lapso entre medidas es de minuto a minuto. Fue por lo anterior que se decidió buscar un dataset adicional capaz de alimentar el anterior, este se obtuvo del "NYC Open Data", específicamente del dataset: "Hyperlocal Temperature Monitoring" el cual mide la temperatura a nivel de la calle (Street level temperature) en vecindarios con mayor riesgo de mortalidad por calor durante junio-septiembre del 2018. Incluye valores promedio por hora en grados Fahrenheit, latitud, longitud, áreas de tabulación en el Bronx y Manhattan, para entender que bloques lo hacen mas caliente o más fresco y por último tiene ubicaciones en calles con arboles y en lamparas (de donde se registraron las temperaturas). Sin embargo no todas las columnas son requeridas, además de faltar el índice UHI, pero es una variable que se puede obtener con la siguiente formula:

$$\text{Índice UHI} = \frac{\text{Temperatura dada una localización}}{\text{Media de la temperatura para todas las localizaciones}}$$

Pasando de este formato:

Sensor.ID	AirTemp	Day	Hour	Latitude	Longitude	Year	Install.Type	Borough	ntacode
Bk-BR_01	71.189000	06/15/2018	1	40.666205	-73.91691	2018	Street Tree	Brooklyn	BK81
Bk-BR_01	70.243333	06/15/2018	2	40.666205	-73.91691	2018	Street Tree	Brooklyn	BK81
Bk-BR_01	69.392667	06/15/2018	3	40.666205	-73.91691	2018	Street Tree	Brooklyn	BK81
Bk-BR_01	68.263167	06/15/2018	4	40.666205	-73.91691	2018	Street Tree	Brooklyn	BK81
Bk-BR_01	67.114000	06/15/2018	5	40.666205	-73.91691	2018	Street Tree	Brooklyn	BK81

Table 1: Dataset Hyperlocal Temperature Monitoring.

A este otro formato:

Longitude	Latitude	datetime	UHI Index	Borough	ntacode
-73.909167	40.813107	24-07-2021 15:53	1.030289	NaN	NaN
-73.909187	40.813045	24-07-2021 15:53	1.030289	NaN	NaN
-73.909215	40.812978	24-07-2021 15:53	1.023798	NaN	NaN
-73.909242	40.812908	24-07-2021 15:53	1.023798	NaN	NaN
-73.909257	40.812845	24-07-2021 15:53	1.021634	NaN	NaN

Table 2: Dataset 'Hyperlocal Temperature Monitoring' modificado a necesidad del challenge.

Este dataset presenta valores nulos debido a que las columnas de 'Borough' y 'ntacode' corresponden a los distritos de New York y al código de tabulación por áreas del vecindario respectivamente, pero esto es esperable debido a que el dataset original no tiene esos datos. Sin embargo, los datos presentados no eran suficientes, por lo que se decidieron agregar bandas espectrales con respecto de estas nuevas coordenadas, para tener mayor información de análisis. Finalmente el dataset alimentado tuvo la siguiente configuración:

Latitude	Longitude	UHI Index	B01	B04	B06	B08	NDVI	Borough	ntacode
40.813107	-73.909167	1.030289	846.0	1036.0	1502.0	1906.0	0.295717	NaN	NaN
40.813045	-73.909187	1.030289	846.0	1036.0	1502.0	1906.0	0.295717	NaN	NaN
40.812978	-73.909215	1.023798	846.0	709.0	1668.0	2190.0	0.510866	NaN	NaN
40.812908	-73.909242	1.023798	846.0	657.0	1668.0	2182.0	0.537161	NaN	NaN
40.812845	-73.909257	1.021634	846.0	745.0	1728.0	2112.0	0.478474	NaN	NaN

Table 3: Dataset original + 'Dataset Hyperlocal Temperature Monitoring'.

Teniendo ya los datasets con los que se trabajara, se realiza un análisis de estos mismos para entender mejor el contenido y las relaciones que pueden existir.

5.1 Análisis Dataset original (DatasetV1)

Lo primero que se debe de mencionar es que no se presentaron valores nulos ni duplicados.

Después se obtuvo una descripción estadística de los datos, obteniendo:

	Longitude	Latitude	UHI Index	B01	B04	B06	B08	NDVI
count	11229.000000	11229.000000	11229.000000	11229.000000	11229.000000	11229.000000	11229.000000	11229.000000
mean	-73.933927	40.808800	1.000001	1577.434233	1639.084691	2150.186036	2225.908273	0.181637
std	0.028253	0.023171	0.016238	1510.100390	1456.841224	1380.281893	1425.736087	0.202704
min	-73.994457	40.758792	0.956122	265.000000	167.000000	245.000000	210.000000	-0.381555
25%	-73.955703	40.790905	0.988577	883.000000	828.000000	1484.000000	1474.000000	0.044431
50%	-73.932968	40.810688	1.000237	1173.000000	1276.000000	1884.000000	1928.000000	0.106618
75%	-73.909647	40.824515	1.011176	1554.000000	1798.000000	2355.000000	2586.000000	0.258089
max	-73.879458	40.859497	1.046036	12280.000000	12736.000000	12682.000000	12992.000000	0.889549

Table 4: Estadísticas descriptivas de los datos

De los datos presentados en la tabla 4, podemos inferir que para el índice UHI se observa un rango de variación no muy amplio (alrededor de 0.09 entre el valor mínimo y el máximo), lo que sugiere niveles de UHI bastante uniformes, aunque con ligeras diferencias locales. En cuanto a las bandas se observa que los valores mínimos son muy bajos (por ejemplo, B01 el mínimo está en 265) y llegan hasta máximos que rondan los 12,000-13,000, lo que demuestra una gran variabilidad en la reflectancia. Entonces, esta dispersión sugiere que el área abarca distintos tipos de superficies (por ejemplo: zonas verdes, agua, superficies urbanas altamente reflectantes, etc.). Por último para el índice NDVI se tiene un rango amplio (aprox. 1.27 desde -0.38 hasta 0.89) poniendo de manifiesto la heterogeneidad de la cobertura terrestre, con áreas muy vegetadas y zonas casi sin vegetación.

Avanzando con el análisis se trabajo con una matriz de correlación, histogramas y gráficas de caja, de las cuales obtuvimos los siguientes resultados:




Figure 1: Matriz de correlación Dataset 1




Figure 2: Histogramas Dataset 1




Figure 3: Gráficas de caja Dataset 1

Con la información obtenida de este análisis se llego a los siguientes puntos.

Matriz de correlación y boxplot

1. Existen correlaciones entre coordenadas y el UHI Index.
2. Existen correlaciones entre las bandas espectrales B01, B04, B06, B08.
3. El NDVI se correlaciona de forma negativa con la mayoría de las bandas, esto es esperado porque se basa en la relación entre la banda del espectro rojo (en donde la vegetación absorbe, siendo la B04) y el infrarrojo cercano (en donde la vegetación refleja, siendo la B08), entonces cuando hay mucha vegetación (alta reflectancia de la banda 08 y baja en la banda 04) el NDVI es alto.
 - (a) Esto significa que a medida que aumenta la reflectancia en la banda 04, el NDVI tiende a disminuir.
4. La banda 08 tiene una correlación positiva de 0.0207, lo que indica una relación débil entre el aumento de la reflectancia en la banda y el NDVI.
5. Se observa una correlación negativa moderada entre el NDVI y el índice UHI, indicando que, a mayor cobertura vegetal, menor será la intensidad de la isla de calor.

Boxplots

1. UHI Index: Distribución concentrada en torno a 1, con outliers cercanos a 1.04.
2. Bandas: Muchos outliers, indicando un sesgo a la derecha y esto puede indicar, con el contexto anterior, superficies muy reflectantes.
3. NDVI: Hay outliers negativos, esto puede ser de casos en donde la banda 04 refleja mucho, pudiendo ser zonas con agua o zonas demasiado áridas.

5.2 Análisis Dataset alimentado (DatasetV2)

Al igual que en el dataset anterior lo primero que se analizó fue la existencia de datos duplicados y nulos, en este caso esta versión de dataset si tiene valores nulos por los detalles mencionados al inicio de la metodología. Por lo que el siguiente aspecto a rescatar es una descripción estadística de los datos, obteniendo:

	Longitude	Latitude	UHI Index	B01	B04	B06	B08	NDVI
count	574297	574297	574297	574297	574297	574297	574297	574297
mean	-73.9086	40.8252	1.0021	1557.33	1584.83	2139.08	2186.02	0.1837
std	0.0351	0.0314	0.1174	813.99	1003.75	892.83	952.99	0.1633
min	-73.9945	40.7588	0.6041	265.00	167.00	245.00	210.00	-0.3816
25%	-73.9452	40.8039	0.9339	1174.00	998.00	1753.00	1730.00	0.0556
50%	-73.9118	40.8103	0.9958	1405.00	1312.00	1986.00	2008.00	0.1427
75%	-73.8856	40.8538	1.0784	1703.00	1926.00	2547.00	2654.00	0.2940
max	-73.8447	40.8846	1.4457	12280.00	12736.00	12682.00	12992.00	0.8895

Table 5: Estadísticas descriptivas DatasetV2

Las principales diferencias que se presentan con el análisis anterior se muestran en la siguiente lista:

- El segundo conjunto es mucho más grande, teniendo 574,297 muestras vs. 11,229. Esto implica que el segundo dataset podría capturar mejor la variabilidad espacial.
- El Índice de Isla de Calor Urbana (UHI Index) está mucho más disperso en el segundo conjunto, presentando una desviación estándar mayor al dataset original, indicando zonas con mayores diferencias de temperatura.
- En cuanto a las bandas espectrales, presentan muchas similitudes en su variabilidad, aunque en este dataset se presenta una menor variabilidad.
- En torno al índice 'NDVI', los valores promedio son muy similares, lo que indica que la vegetación en la región no varía demasiado en ambos conjuntos, pero sí se abarca un área más grande, con mayor dispersión en latitud y longitud.

A continuación se presenta el análisis realizado con una matriz de correlación, histogramas y gráficas de caja, de las cuales se obtuvo:



Figure 4: Matriz de correlación Dataset 2




Figure 5: Histogramas Dataset 2




Figure 6: Gráficas de caja Dataset 2

- En este conjunto, la distribución del UHI Index es más asimétrica, con una cola larga hacia valores altos, mientras que en el primer dataset estaba más concentrado en torno a 1.
- En el primer dataset, los histogramas mostraban una mayor concentración de valores bajos, mientras que en este segundo conjunto hay una mayor dispersión de valores altos, especialmente en las bandas B04 y B08.
- La distribución del índice NDVI está más dispersa.

En general, este dataset alimentado presenta más valores extremos, lo que sugiere la existencia de un mayor número de superficies con alta reflectancia.

5.3 Análisis Dataset original con características añadidas

Al igual que en los dataset anteriores lo primero que se analizo fue la existencia de datos duplicados y nulos, en este caso esta version de dataset.

6 Resultados

Los resultados se dividen en tres partes, todas ellas son en base al conjunto de test establecido en cada sección del código, el cual se puede observar en el siguiente github: <https://github.com/JonathanMedellin1/Data-Challenge-EY-2025.git>

Además, para evaluar la precisión del modelo se decidió utilizar el coeficiente de determinación, también conocido como R^2 . En donde se tuvieron los siguientes resultados:

Dataset	Precisión del modelo
DatasetV1	34.75%
DatasetV2	0.75%
DatasetV1 con características añadidas	60.29%

Table 6: Precisión del modelo en diferentes conjuntos de datos

7 Conclusión

Las diferencias en el ajuste de los modelos, cuando se agrega el NDWI, pudieron deberse a que al tratarse de vapor de agua este puede estar influyendo de manera positiva al calentamiento de la superficie debido a sus propiedades de retención de energía de onda larga, sin embargo, al ser una medida tomada de manera satelital este tiene una influencia negativa debido a nubosidad (al igual que el resto de índices) que afecta principalmente como se relaciona al utilizar los índices de vegetación y urbanismo ya que estos también tienen influencia de nubosidad y las posibles relaciones entre los píxeles de nubosidad para los tres índices impiden que el NDWI sea un índice que proporcione una mejora en el ajuste.